

Hacia la implementación de un modelo neuronal de integración multisensorial de inferencia probabilística con dinámicas corticales realistas

Autor(es) anonimizado(s) para revisión a ciegas

Afiliación anonimizada para revisión a ciegas

Resumen La integración multisensorial, el proceso mediante el cual el cerebro combina información de distintas modalidades sensoriales, constituye un área fundamental de la neurociencia computacional. Los modelos existentes presentan una brecha significativa: aquellos que capturan la arquitectura funcional de la integración multisensorial carecen de dinámicas corticales realistas, mientras que los modelos con dinámicas biológicamente plausibles están limitados al procesamiento unimodal. Este trabajo aborda el primer paso hacia dicha fusión mediante la implementación del modelo unimodal de Echeveste et al. (2020), que opera sobre una única modalidad sensorial (visual), dentro del framework Scikit-NeuroMSI, una plataforma de código abierto en Python para la modelización neurocomputacional de la integración multisensorial. Al integrar este modelo unimodal en un framework multimodal, se sientan las bases para su futura extensión hacia el procesamiento de múltiples modalidades sensoriales. La reimplementación, desde Python/OCaml hacia Python/JAX, fue validada alcanzando equivalencia numérica con errores del orden de 10^{-15} . Como contribuciones adicionales, se desarrollaron dos módulos de soporte para gestión de parámetros pre-entrenados y para modelos generativos, posicionando esta implementación como base técnica fundamental para la futura investigación planteada que combina dinámicas corticales realistas con integración multisensorial.

Keywords: inferencia probabilística – muestreo neuronal – redes recurrentes – integración multisensorial – Scikit-NeuroMSI

Towards the implementation of a neural model of multisensory integration for probabilistic inference with realistic cortical dynamics

Abstract Multisensory integration, the process by which the brain combines information from different sensory modalities, constitutes a fundamental area of computational neuroscience. Existing models present a significant gap: those that capture the functional architecture of multisensory integration lack realistic cortical dynamics, while models with biologically plausible dynamics are limited to unimodal processing. This work addresses the first step towards bridging this gap through the implementation of the unimodal model of Echeveste et al. (2020),

which operates on a single sensory modality (visual), within the Scikit-NeuroMSI framework, an open-source Python platform for neurocomputational modeling of multisensory integration. By integrating this unimodal model into a multimodal framework, the foundations are laid for its future extension towards multisensory processing. The reimplementaion, from Python/OCaml to Python/JAX, was validated through four complementary levels: unit testing of individual components, function-by-function comparison against the original code achieving numerical equivalence with errors on the order of 10^{-15} , robustness analysis of the two-stage training procedure across 100 independent runs, and replication of the central simulations of the original article. The implemented network faithfully reproduces probabilistic inference via sampling, exhibiting characteristic emergent properties such as stimulus-modulated variability (quenching), inhibitory transients, and gamma-band oscillations whose peak frequency increases with stimulus contrast. As additional contributions, two support modules were developed for managing pre-trained parameters and generative models, positioning this implementation as a fundamental technical foundation for the proposed future research combining realistic cortical dynamics with multisensory integration.

Keywords: probabilistic inference – neural sampling – recurrent networks – multisensory integration – Scikit-NeuroMSI

1 Introducción

La integración multisensorial es un proceso neuronal fundamental mediante el cual el cerebro combina información proveniente de distintas modalidades sensoriales para generar representaciones más robustas y confiables del entorno. Este fenómeno, documentado extensamente desde los estudios pioneros en el colículo superior (Stein, 2012), constituye una de las capacidades más notables del sistema nervioso.

Diversos enfoques computacionales han buscado capturar los mecanismos subyacentes a esta integración. Entre estos desarrollos, dos trabajos resultan particularmente relevantes por representar enfoques complementarios al problema. Por un lado, el modelo de Cuppini et al. (2017) aborda la integración audiovisual mediante una arquitectura de tres capas jerárquicas que reproduce fenómenos experimentales como el efecto ventrilocuo. Sin embargo, al utilizar modelos de tasa deterministas, este enfoque no captura la variabilidad ni las dinámicas oscilatorias características de la actividad cortical real. Por otro lado, el modelo de Echeveste et al. (2020) demuestra que redes neuronales con restricciones biológicas pueden implementar inferencia probabilística mediante muestreo estocástico, exhibiendo propiedades emergentes como oscilaciones gamma y variabilidad modulada por el estímulo; no obstante, este modelo está restringido al procesamiento unimodal.

Esta situación revela una brecha significativa: los modelos que capturan la arquitectura funcional de la integración multisensorial carecen de dinámicas corticales realistas, mientras que aquellos con dinámicas biológicamente plausibles están limitados al procesamiento unimodal. La visión a largo plazo que motiva este trabajo es el desarrollo de modelos que combinen la arquitectura multimodal del enfoque de Cuppini con las dinámicas corticales del modelo de Echeveste. Alcanzar esta visión, sin embargo, requiere primero sentar bases técnicas sólidas.

El presente trabajo representa el primer paso en esta dirección mediante la implementación del modelo de Echeveste dentro del framework Scikit-NeuroMSI (Paredes et al., 2025), una plataforma de código abierto en Python¹ diseñada específicamente para la modelización neurocomputacional de la integración multisensorial. Esta implementación incluye la arquitectura de red con poblaciones excitatorias e inhibitorias, el modelo generativo que define el problema de inferencia, y el procedimiento de entrenamiento para muestreo.

2 El modelo de Echeveste

El trabajo de Echeveste et al. (2020) parte de restricciones biológicas sobre la dinámica de circuitos corticales para demostrar que redes neuronales recurrentes pueden ser optimizadas para implementar inferencia probabilística basada en muestreo. Se trata de un modelo *unimodal*: opera exclusivamente sobre estímulos visuales, modelando una hipercolumna de la corteza visual primaria donde las neuronas responden a la orientación de bordes en el campo visual, sin abordar la integración de múltiples modalidades sensoriales. A continuación, se describen los componentes centrales.

2.1 Marco teórico: muestreo como inferencia

La percepción puede entenderse como inferencia bayesiana sobre las causas latentes de las observaciones sensoriales. Dado un estímulo $\mathbf{x}$, el cerebro busca inferir las variables latentes $\mathbf{y}$ que lo generaron, caracterizadas por la distribución posterior $P(\mathbf{y}|\mathbf{x})$. La hipótesis del *muestreo neuronal* propone que, en lugar de representar esta distribución analíticamente, el cerebro la representa mediante muestras temporales, de modo que la distribución empírica de actividades a lo largo del tiempo aproxima la posterior (Echeveste et al., 2020).

2.2 El modelo generativo (GSM)

Para especificar el problema computacional objetivo, se adopta el *modelo de mezcla de escala gaussiana* (GSM), un modelo generativo que captura las estadísticas de parches de imágenes naturales. Un parche $\mathbf{x} \in \mathbb{R}^{N_x}$ se genera como:

$$\mathbf{x} = z \cdot \mathbf{A}\mathbf{y} + \varepsilon, \quad \mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{C}) \quad (1)$$

donde $\mathbf{y}$ son variables latentes, $\mathbf{A}$ es la matriz de campos proyectivos tipo Gabor, z es el contraste, y ε es ruido sensorial. Bajo el GSM, la posterior sobre las variables latentes dado un parche $\mathbf{y}$ y un contraste conocido tiene forma gaussiana, con media y covarianza que dependen de z de manera que a mayor contraste, menor incertidumbre.

¹ <https://www.python.org/>

2.3 Dinámica neuronal y arquitectura

El modelo implementa una *red supralineal estabilizada* (SSN) que modela una hiper-columna de V1, con $N_E = N_I = 50$ neuronas organizadas en una topología de anillo según sus orientaciones preferidas. La dinámica de cada neurona está gobernada por:

$$\tau_i \frac{du_i}{dt} = -u_i(t) + h_i(t) + \sum_j W_{ij} r_j(t) + \eta_i(t) \quad (2)$$

donde u_i es el potencial de membrana, h_i la entrada feedforward, W_{ij} los pesos recurrentes, $r_j = k[u_j]_+^n$ la tasa de disparo con no linealidad supralineal, y η_i ruido gaussiano correlacionado. La conectividad $\mathbf{W}$ se parametriza de forma rotacionalmente simétrica, reduciendo los grados de libertad de $N^2 = 10,000$ a solo 15 parámetros totales que respetan el principio de Dale.

2.4 Entrenamiento para muestreo

A diferencia de enfoques tradicionales, el objetivo es que la *distribución* de respuestas de la red coincida con la posterior del modelo generativo. Para ello se minimiza una función de costo que penaliza diferencias entre los momentos de la red y los momentos objetivo de la posterior, junto con un término de *slowness* que incentiva independencia temporal entre muestras:

$$\mathcal{F} = \sum_{\alpha} \left(\epsilon_{\mu} \phi_{\mu}^{(\alpha)} + \epsilon_{\sigma} \phi_{\sigma}^{(\alpha)} + \epsilon_{\Sigma} \phi_{\Sigma}^{(\alpha)} + \epsilon_{\text{slow}} \phi_{\text{slow}}^{(\alpha)} \right) \quad (3)$$

El procedimiento de optimización se realiza en dos etapas: una estocástica con ADAM (250 iteraciones, $N_{\text{trial}} = 50$) y una determinística con L-BFGS-B que emplea el método *Assumed Density Filtering* (ADF) para obtener gradientes exactos bajo una aproximación gaussiana de la distribución conjunta espacio-temporal.

3 Implementación

Con el conocimiento del modelo de Echeveste, procedemos a describir en detalle las decisiones de diseño, los desafíos que enfrentamos y las contribuciones realizadas al framework Scikit-NeuroMSI.

3.1 Arquitectura del código

La implementación se organizó en cinco módulos dentro del paquete `skneuromsi/neural/echeveste2020`, separando responsabilidades según el principio de responsabilidad única: `_model.py` con la clase principal `Echeveste2020`; `_training.py` con las funciones de entrenamiento basadas en diferenciación automática; `_gsm.py` con el modelo generativo; `_visualization.py` con herramientas de análisis para dinámicas temporales; y `_data_loader.py` con el acceso a parámetros pre-entrenados. La clase `Echeveste2020` hereda de `SKNMSIMethodABC`, lo que garantiza compatibilidad con las herramientas del framework.

3.2 Reimplementación en JAX

Uno de los desafíos inesperados del trabajo fue descubrir que el código de entrenamiento original se encontraba implementado en OCaml², un lenguaje funcional atípico para el desarrollo actual de modelos de redes neuronales. En comunicación personal con el autor original, pudimos comprender que, al momento en que se desarrolló el modelo, las herramientas de diferenciación automática hoy consideradas estándar no existían o no habían alcanzado la madurez necesaria para este tipo de aplicaciones. Sin embargo, esta decisión técnica, perfectamente razonable en su contexto original, dejó el código en un estado de difícil acceso para la comunidad científica actual.

La reimplementación en JAX³ constituyó, por tanto, no solo una traducción de código sino una actualización tecnológica sustancial. JAX fue la elección natural por varias razones: su paradigma de programación funcional guarda afinidad conceptual con OCaml, lo que facilitó la traducción de las estructuras algorítmicas; ya se encontraba integrado en Scikit-NeuroMSI como dependencia para otros componentes; y ofrece compilación *Just-In-Time* mediante XLA que optimiza automáticamente las operaciones para el hardware disponible, junto con soporte transparente para ejecución en GPU.

3.3 Módulos de soporte

Además de la implementación central, el trabajo contribuyó estructurando dos módulos completamente nuevos al framework. El módulo *data* fue implementado como infraestructura para gestionar el acceso a datos pre-entrenados, exportando las clases *EchevesteDataLoader* y *GSMDataLoader* que proporcionan acceso estructurado a la matriz de conectividad optimizada, la matriz de covarianza de ruido, los parámetros de la transformación de entrada, y los componentes del modelo generativo.

El módulo *generative* representa una extensión conceptual significativa del framework, introduciendo por primera vez la capacidad de definir modelos generativos que especifican el problema de inferencia. Actualmente contiene la clase *GSM*, aunque la arquitectura fue diseñada con extensibilidad en mente: futuros trabajos podrían agregar otros modelos generativos siguiendo la misma interfaz.

3.4 Modos de simulación

La implementación soporta dos modos de simulación. El *modo de fase única* mantiene el estímulo presente durante toda la simulación y replica las condiciones utilizadas durante el entrenamiento. El *modo de tres fases* divide la simulación en períodos pre-estímulo, estímulo y post-estímulo, permitiendo estudiar fenómenos dinámicos como los transitorios al *onset* y las oscilaciones moduladas por el estímulo. El modo de tres fases soporta opcionalmente *delays* por neurona en las transiciones, modelando la variabilidad temporal con que diferentes neuronas reciben la señal de entrada.

² <https://ocaml.org/>

³ <https://docs.jax.dev/>

4 Resultados

La validación de la implementación se realizó en cuatro niveles complementarios: pruebas unitarias, validación función por función, análisis del procedimiento de entrenamiento, y reproducción de las simulaciones centrales del artículo original.

4.1 Validación función por función

Se realizó una validación exhaustiva comparando cada función de nuestra implementación con su equivalente en el código original. La metodología consistió en generar $N = 10,000$ muestras aleatorias para cada función, ejecutar ambas implementaciones con inputs idénticos, y calcular el error máximo absoluto. La Tabla 1 presenta el resumen por categoría.

Table 1. Validación función por función contra el código original de Echeveste ($N = 10,000$ muestras por función).

# Categoría	Error máximo
1 Distribución Normal	0.00
2 Activación Neuronal	0.00
3 Momentos v, γ	7.11×10^{-15}
4 Evolución Temporal	0.00
5 Conectividad Paramétrica	0.00
6 Ruido Ornstein–Uhlenbeck	1.11×10^{-16}
7 GSM Posterior	0.00
8 Funciones Auxiliares	0.00

Los resultados demuestran que las 25 funciones evaluadas producen resultados numéricamente equivalentes, con errores máximos del orden de la precisión de punto flotante de doble precisión ($\sim 10^{-15}$). Los errores no nulos observados corresponden exactamente al épsilon de máquina IEEE 754 ($\epsilon \approx 2.22 \times 10^{-16}$), y surgen de diferencias en el orden de operaciones aritméticas entre implementaciones, no de discrepancias algorítmicas.

4.2 Convergencia del entrenamiento

Para evaluar la robustez del procedimiento, se ejecutaron 100 corridas independientes partiendo de condiciones iniciales aleatorias. Las amplitudes de conectividad convergieron consistentemente hacia los valores de referencia, con coeficientes de variación menores al 10% en la mayoría de los casos. Los parámetros de la transformación de entrada ($\alpha_h, \beta_h, \gamma_h$) exhibieron errores relativos menores al 5% respecto a los valores reportados. El exponente $\gamma_h \approx 2$ resulta particularmente notable: su proximidad al exponente supralineal $n = 2$ sugiere una consistencia en el procesamiento no lineal a través del modelo, que emerge de la optimización sin ser impuesta *a priori*.

Los parámetros del ruido revelaron un fenómeno interesante: las desviaciones estándar σ_E y σ_I exhibieron mayor variabilidad entre corridas, pero la proporción σ_E/σ_I se mantuvo aproximadamente constante, indicando la existencia de una familia de soluciones equivalentes en el espacio de parámetros.

4.3 Actividad poblacional y patrones de disparo

La validación de las propiedades de inferencia se inicia verificando que la red reproduce los patrones de actividad poblacional reportados en el artículo original. La Figura 1 muestra los potenciales de membrana excitatorios u_E en función del tiempo y la orientación para los casos extremos de contraste.

En ausencia de estímulo, la actividad fluctúa alrededor de valores bajos con distribución espacial aproximadamente uniforme, reflejando el ruido de proceso $\eta(t)$ filtrado por la dinámica recurrente. Con contraste máximo, la presencia de un estímulo con orientación dominante en 0 induce un incremento de actividad centrado en las neuronas con orientación preferida cercana a esta dirección.

Una representación complementaria se obtiene mediante *raster plots*, donde cada marca vertical representa un potencial de acción. La Figura 2 compara la actividad espontánea con la evocada por estímulo. Notablemente, las neuronas inhibitorias (rojo) exhiben tasas de disparo superiores a las excitatorias (azul) en ambas condiciones, comportamiento consistente con la dinámica de redes supralineales estabilizadas donde la inhibición debe ser suficientemente fuerte para prevenir la excitación descontrolada inducida por el estímulo.

4.4 Estructura de correlaciones poblacionales

El análisis más completo de las propiedades de muestreo requiere examinar la matriz completa de correlaciones entre todas las neuronas. La Figura 3 presenta esta comparación, mostrando que las matrices exhiben la estructura característica de la topología de anillo.

La diagonal principal muestra máxima correlación, y a medida que nos alejamos de la diagonal, la correlación decae gradualmente, reflejando que neuronas con orientaciones preferidas más distantes están menos correlacionadas. La estructura se modifica con el contraste de manera consistente entre el observador ideal y la red: para contraste cero, las correlaciones están determinadas principalmente por el prior del GSM, mientras que con el aumento del contraste, la estructura refleja progresivamente más la información del estímulo. Calculando la correlación de Pearson elemento por elemento entre ambas matrices, se obtienen valores superiores a 0.95 para todos los niveles de contraste, confirmando que la red no solo reproduce los momentos marginales correctos sino también la estructura completa de dependencias.

4.5 Dinámicas emergentes

Más allá de reproducir los momentos estadísticos correctos, el modelo de Echeveste se distingue por exhibir un conjunto de propiedades dinámicas que emergen como con-




Fig. 1. Actividad poblacional de potenciales de membrana excitatorios. Primer panel: contraste $z = 0$ (actividad espontánea). Panel central: contraste $z = 1$ (estimulación máxima). Último panel: entrada feedforward $\mathbf{h}$ correspondiente al contraste máximo. El eje vertical representa la orientación preferida de cada neurona (-90 a 90); el eje horizontal, el tiempo.

secuencia del objetivo de muestreo, sin ser explícitamente impuestas durante el entrenamiento. Nuestra implementación preserva estas características, las cuales se describen a continuación.




Fig. 2. Raster plot comparando actividad espontánea y evocada. Cada marca vertical representa un spike. Neuronas excitatorias en azul, inhibitorias en rojo. Panel superior: actividad espontánea sin estímulo, mostrando disparos dispersos distribuidos uniformemente. Panel inferior: actividad durante presentación de estímulo a 0 (línea punteada verde) de alto contraste $z = 1.0$, con disparos concentrados alrededor de la orientación del estímulo.

Variabilidad modulada por el estímulo. La varianza de las respuestas neuronales decrece con el contraste del estímulo, fenómeno conocido como *quenching* y observado experimentalmente en corteza visual de primates (Echeveste et al., 2020). Este comportamiento puede cuantificarse mediante el factor de Fano, $F = \text{Var}[r]/\mathbb{E}[r]$, cuya reducción sistemática con el contraste verificamos en nuestras simulaciones: para $z = 0$ se encuentra en el rango 1.0–1.2, mientras que para $z = 1$ decrece hacia valores en 0.6–0.8. La reducción es particularmente pronunciada para las neuronas cuya orientación preferida coincide con la del estímulo, reflejando directamente las propiedades de la posterior del GSM, donde mayor contraste implica menor incertidumbre.




Fig. 3. Matrices de correlación de Pearson entre potenciales de membrana excitatorios. Columna izquierda: observador ideal (GSM). Columna derecha: red neuronal (SSN). Cada fila corresponde a un nivel de contraste diferente.

Transitorios inhibitorios. Al inicio de un estímulo, la inhibición domina transitoriamente sobre la excitación, generando sobrepicos (*overshoots*) en las tasas de disparo poblacionales seguidos de adaptación hacia el estado estacionario. Lejos de constituir defectos del modelo, estos transitorios cumplen un rol funcional al acelerar la convergencia de las muestras hacia la distribución estacionaria correcta, reduciendo el tiempo de *burn-in*. El análisis teórico de Echeveste et al. (2020) muestra que la trayectoria óptima que minimiza el error de estimación en una ventana temporal finita debe ex-

hibir sobrepicos cuya magnitud escala con el valor objetivo, predicción que validaron mediante registros experimentales en V1 de mono despierto.

Oscilaciones gamma. La actividad de la red exhibe oscilaciones en el rango gamma (30–80 Hz), detectables tanto en autocorrelogramas de neuronas individuales como en el potencial de campo local (LFP) simulado, calculado como el promedio de los potenciales de membrana excitatorios. La frecuencia pico aumenta con el contraste del estímulo, comportamiento que verificamos en nuestras simulaciones mediante análisis espectral de Welch sobre el LFP: la frecuencia pico se desplaza desde ~ 32 Hz para contraste bajo hasta ~ 56 Hz para contraste máximo. Estas oscilaciones implementan una forma de muestreo fuera del equilibrio que acelera la exploración del espacio de estados: a diferencia de algoritmos de muestreo clásicos como Langevin (cuya dinámica reversible limita la velocidad de mezcla), las trayectorias oscilatorias de la red optimizada permiten que muestras consecutivas cubran una región más amplia del espacio, alcanzando convergencia un orden de magnitud más rápido. Este resultado es particularmente significativo dado que las oscilaciones gamma se observan consistentemente en registros electrofisiológicos de V1 de primates, sugiriendo que podrían constituir un subproducto funcional del cómputo probabilístico más que un epifenómeno.

5 Conclusiones y trabajo a futuro

En este trabajo llevamos a cabo la implementación completa del modelo de Echeveste et al. (2020) dentro del framework Scikit-NeuroMSI, estableciendo las bases técnicas necesarias para futuras investigaciones que combinen dinámicas corticales realistas con integración multisensorial. La reimplementación, que requirió una traducción completa desde OCaml hacia Python utilizando JAX para diferenciación automática, resultó en una implementación moderna compatible con el ecosistema actual, con soporte transparente para aceleración en GPU y una arquitectura modular que facilita futuras extensiones.

La validación se realizó en múltiples niveles complementarios. La verificación función por función demostró equivalencia numérica exacta con errores del orden de la precisión de punto flotante. Las pruebas del procedimiento de entrenamiento confirmaron que los parámetros optimizados convergen hacia valores comparables a los de referencia. Las simulaciones replicaron las figuras centrales del artículo original, verificando que la red implementada reproduce correctamente las propiedades de inferencia probabilística mediante muestreo y las dinámicas temporales características, incluyendo oscilaciones gamma cuya frecuencia aumenta con el contraste.

Como contribuciones adicionales al framework, se desarrollaron los módulos `data` (infraestructura para gestionar parámetros pre-entrenados) y `generative` (que introduce por primera vez modelos generativos como el GSM, diseñado con extensibilidad en mente).

La dirección más prometedora para trabajo futuro es la integración del modelo de Echeveste con el modelo de Cuppini ya implementado en Scikit-NeuroMSI. Sin embargo, esta fusión requiere resolver adaptaciones fundamentales que van más allá de una integración directa. La diferencia más significativa reside en el dominio de representación neuronal: las neuronas del modelo de Echeveste están organizadas según su

orientación preferida de estímulos visuales (topología de anillo en una hipercolumna de V1), mientras que las neuronas del modelo de Cuppini están organizadas topográficamente según la *posición espacial* en el campo visual y auditivo. Esta diferencia implica que la conectividad, las funciones de sintonización y el modelo generativo subyacente operan sobre espacios de características distintos. Entre las principales adaptaciones necesarias se encuentran: (i) rediseñar la topología de la red para que las neuronas respondan a posición espacial en lugar de orientación, lo cual modifica la parametrización circulante de la matriz de conectividad; (ii) reformular el modelo generativo, reemplazando el GSM basado en filtros de Gabor orientados por uno que capture las estadísticas de localización espacial de estímulos audiovisuales; (iii) extender la arquitectura de una red unimodal a múltiples capas interconectadas (auditiva, visual y multisensorial) preservando las dinámicas de muestreo estocástico; y (iv) incorporar mecanismos de inferencia causal que determinen si estímulos de distintas modalidades provienen de una causa común o de fuentes independientes. A diferencia de los modelos deterministas de tasa existentes, un modelo así generaría señales de LFP simuladas con oscilaciones emergentes en bandas fisiológicamente relevantes, lo que abriría la posibilidad de modelar directamente las dinámicas oscilatorias cerebrales asociadas a la integración multisensorial y contrastarlas con registros electrofisiológicos reales.

Otras líneas complementarias incluyen la extensión de la validación experimental del modelo mediante réplicas de análisis como los de Bányai et al. (2019), la implementación de otros modelos generativos dentro del módulo *generative* para investigar sistemáticamente cómo las propiedades emergentes del circuito dependen del problema de inferencia que la red debe resolver, y la formalización de la separación entre generación de estímulos y modelos neuronales, como propone Paredes et al. (2025).

6 Agradecimientos

Agradecimientos omitidos para revisión a ciegas. Serán incluidos en la versión final del manuscrito.

Referencias

- Bányai, M., Lazar, A., Klein, L., Klon-Lipok, J., Stippinger, M., Singer, W., & Orbán, G. (2019). Stimulus complexity shapes response correlations in primary visual cortex. *Proceedings of the National Academy of Sciences*, 116(7), 2723–2732.
- Berkes, P., Orbán, G., Lengyel, M., & Fiser, J. (2011). Spontaneous cortical activity reveals hallmarks of an optimal internal model of the environment. *Science*, 331(6013), 83–87.
- Cuppini, C., Shams, L., Magosso, E., & Ursino, M. (2017). A biologically inspired neurocomputational model for audiovisual integration and causal inference. *European Journal of Neuroscience*, 46(9), 2481–2498.
- Echeveste, R., Aitchison, L., Hennequin, G., & Lengyel, M. (2020). Cortical-like dynamics in recurrent circuits optimized for sampling-based probabilistic inference. *Nature Neuroscience*, 23(9), 1138–1149.

- Gerstner, W., & Kistler, W. M. (2002). *Spiking neuron models: Single neurons, populations, plasticity*. Cambridge University Press.
- Haefner, R. M., Berkes, P., & Fiser, J. (2016). Perceptual decision-making as probabilistic inference by neural sampling. *Neuron*, 90(3), 649–660.
- Körding, K. P., Beierholm, U., Ma, W. J., Quartz, S., Tenenbaum, J. B., & Shams, L. (2007). Causal inference in multisensory perception. *PLoS One*, 2(9), e943.
- Paredes, R., Cabral, J. B., & Seriès, P. (2025). Scikit-NeuroMSI: A generalized framework for modeling multisensory integration. *Neuroinformatics*, 23(3), 40.
- Stein, B. E. (2012). *The new handbook of multisensory processing*. MIT Press.
- Ursino, M., Cuppini, C., & Magosso, E. (2017). Multisensory Bayesian inference depends on synapse maturation during training: Theoretical analysis and neural modeling implementation. *Neural Computation*, 29(3), 735–782.